

GeoNexus-RSD 方法路线说明

层次与上下文感知的遥感旋转目标检测研究路线

Dinghao Li

2026 年 5 月 24 日

目录

1	文档目的	2
2	总体研究目标	2
3	整体结构图	2
4	当前已经完成的工作	3
4.1	数据与实验流程	3
4.2	提示词与层次结构	3
4.3	场景上下文提示适配	4
4.4	伪标签净化	5
5	当前定位失败诊断与 anchor repair	6
5.1	问题现象	6
5.2	原始绝对解码	6
5.3	锚定中心解码	6
6	从输入到输出的完整数值例子	7
6.1	步骤 1: 原始大图切片	7
6.2	步骤 2: Backbone 提取特征	8
6.3	步骤 3: Query 网格生成	8
6.4	步骤 4: Anchored box 解码	9
6.5	步骤 5: Prompt bank 分类	9

目录	2
6.6 步骤 6: 层次一致性检查	10
6.7 步骤 7: 伪标签净化打分	10
6.8 步骤 8: Rotated NMS	11
6.9 完整流程小结图	11
7 后续可转向的方向	11
7.1 几条路线之间的关系	11
7.2 方向 A: 继续修复轻量 scaffold	11
7.3 方向 B: 引入强旋转检测器作为 S0	12
7.4 方向 C: 把当前工作定位成方法路线和失败分析	13
7.5 方向 D: 缩小论文目标	14
7.6 方向 E: 只做层次提示和 prompt robustness	14
7.7 方向 F: 只做伪标签净化	14
7.8 方向 G: Routing 作为后续可选模块	14
8 当前主要问题与解决方案	15
9 推荐执行顺序	15
10 最终论文中应避免的表述	15
11 一句话总结	16

1 文档目的

本文用中文系统说明 GeoNexus-RSD 到目前为止已经完成和正在推进的方法路线。重点不是夸大结果，而是把当前研究从代码、实验、数学形式和后续选择四个层面整理清楚。本文可以作为后续论文写作、组会汇报和服务器实验记录的技术底稿。

当前结论必须保持保守：本仓库已经打通 DOTA 风格数据加载、提示词构建、轻量检测器、验证流程和定位修复实验配置，但现有轻量 scaffold 的 DOTA v1.0/v1.5 验证 AP50 仍接近零，只能说明流程跑通，不能作为方法有效性的论文证据。因此，下一步应优先修复检测器定位路径或引入强的旋转检测器基线，然后再运行层次提示、场景上下文和伪标签净化消融。

2 总体研究目标

给定遥感图像切片 I ，目标是预测一组旋转目标框和类别：

$$\mathcal{Y} = \{(b_i, c_i, s_i)\}_{i=1}^N, \quad b_i = (x_i, y_i, w_i, h_i, \theta_i).$$


各符号含义如下：

- I : 输入遥感图像切片，例如 1024×1024 的 DOTA tile。
- N : 模型最终保留的目标数量。
- b_i : 第 i 个目标的旋转框。
- x_i, y_i : 旋转框中心坐标，通常归一化到 $[0, 1]$ 。
- w_i, h_i : 旋转框宽高，通常归一化到 $[0, 1]$ 。
- θ_i : 旋转角度，当前实现中限制在 $[-\pi/2, \pi/2]$ 。
- c_i : 类别，例如 plane、ship、small-vehicle。
- s_i : 检测置信度。

GeoNexus-RSD 的核心问题是：遥感目标小、密集、旋转角度任意，且细粒度类别容易混淆。单纯依靠固定类别分类器很难充分利用“车辆属于交通设施”、“船通常出现在水域或港口”这类语义和场景知识。因此，本路线尝试把视觉语言提示词、类别层次结构和场景上下文引入旋转检测。

3 整体结构图


GeoNexus-RSD 可以理解为在旋转目标检测器外部增加一条“语义提示路线”，再把视觉特征和文本语义在 query/head 阶段融合。整体结构如下。



这张图中有两条主线：

- 视觉主线：输入图像 → backbone → query → 检测头 → NMS → 输出检测结果。
- 语义主线：类别层次树 → prompt bank → 文本嵌入 → 场景适配 → 检测头分类。

如果使用伪标签净化，还会增加一条 teacher/student 或离线过滤路线：



4 当前已经完成的工作

4.1 数据与实验流程

当前仓库已经具备以下基础能力：

- DOTA 风格数据配置和加载，包括 DOTA v1.0、v1.5 和 v2 模板。
- reduced tiled baseline 的训练与验证流程。
- DOTA 风格 AP50 验证接口，用于流程 sanity check。
- 实验配置文件、诊断脚本和服务器运行记录。

已经记录的服务器证据包括：

- DOTA v1.0 reduced tiled baseline：在 4055 张验证 tile 上 $AP50 = 3.326794065590851 \times 10^{-6}$ 。
- DOTA v1.5 matched baseline：在 4055 张验证 tile 上 $AP50 = 1.0926445202230628 \times 10^{-5}$ 。

这两个数值极低，只能说明训练和评估流程能够运行。它们不能支持任何性能提升或论文 claim。

4.2 提示词与层次结构

当前实现包含 prompt bank，即每个类别不只对应一个类别名，而是对应一组提示词：

$$\mathcal{P}_c = \{p_{c,1}, p_{c,2}, \dots, p_{c,K}\}.$$

符号含义：

- c ：类别索引，例如 small-vehicle。
- $\mathcal{P}_c$ ：类别 c 的提示词集合。
- $p_{c,k}$ ：类别 c 的第 k 条提示词。
- K ：该类别提示词数量。

提示词可以包括类别名、父类、别名、场景描述和对比描述。例如 small-vehicle 可以写成：

- “a small vehicle in an aerial image”
- “a road vehicle smaller than a truck”

- “not a storage tank or ship”

文本编码器把提示词变成向量:

$$\mathbf{e}_{c,k} = T(p_{c,k}),$$

其中 $T(\cdot)$ 是文本编码器, $\mathbf{e}_{c,k} \in \mathbb{R}^d$ 是 d 维文本向量。

类别基础嵌入为:

$$\bar{\mathbf{e}}_c = \sum_{k=1}^K \alpha_{c,k} \mathbf{e}_{c,k}, \quad \sum_{k=1}^K \alpha_{c,k} = 1.$$

符号含义:

- $\bar{\mathbf{e}}_c$: 类别 c 的综合提示词嵌入。
- $\alpha_{c,k}$: 第 k 条提示词的权重。
- 当没有学习权重时, 可令 $\alpha_{c,k} = 1/K$ 。

数值例子: 若某类有 $K = 3$ 条提示词, 权重分别为 0.5, 0.3, 0.2, 三个文本向量的一维简化值为 2.0, 1.0, 3.0, 则综合嵌入的一维值为:

$$\bar{e}_c = 0.5 \times 2.0 + 0.3 \times 1.0 + 0.2 \times 3.0 = 1.9.$$

4.3 场景上下文提示适配

遥感目标往往需要上下文。例如同样是细长结构, 在水域附近可能是船, 在陆地道路附近可能是桥或车辆。因此引入场景上下文适配器:

$$\tilde{\mathbf{e}}_{c,i} = \bar{\mathbf{e}}_c + A([\mathbf{g}, \mathbf{r}_i, \bar{\mathbf{e}}_c]).$$

符号含义:

- $\tilde{\mathbf{e}}_{c,i}$: 针对第 i 个 query 或候选区域的上下文适配后类别嵌入。
- $\mathbf{g}$: 整张 tile 的全局场景特征。
- $\mathbf{r}_i$: 第 i 个 query 或候选区域的局部视觉特征。
- $[\cdot]$: 向量拼接。
- $A(\cdot)$: 轻量适配器, 通常是 MLP。

分类 logit 使用归一化相似度:

$$z_{i,c} = \tau^{-1} \frac{\phi(\mathbf{r}_i)^\top \psi(\tilde{\mathbf{e}}_{c,i})}{\|\phi(\mathbf{r}_i)\|_2 \|\psi(\tilde{\mathbf{e}}_{c,i})\|_2}.$$

符号含义:

- $z_{i,c}$: 第 i 个 query 属于类别 c 的分类 logit。
- $\phi(\cdot)$: 视觉投影层。
- $\psi(\cdot)$: 文本投影层。
- τ : 温度系数, 越小则 logit 放大越明显。
- $\|\cdot\|_2$: 二范数。

数值例子：若归一化后的视觉向量和文本向量余弦相似度为 0.72，温度 $\tau = 0.1$ ，则：

$$z_{i,c} = 0.72/0.1 = 7.2.$$

若另一个类别相似度为 0.41，logit 为 4.1，softmax 后前者概率会明显更高。

4.4 伪标签净化

伪标签用于半监督训练，但遥感伪标签噪声很大。当前方法路线把一个候选伪标签的综合质量写成：

$$q_j = \sigma(\beta_1 d_j + \beta_2 h_j + \beta_3 v_j + \beta_4 a_j).$$

符号含义：

- q_j ：第 j 个候选伪标签的净化质量分数。
- $\sigma(\cdot)$ ：sigmoid 函数，把实数映射到 $[0, 1]$ 。
- d_j ：检测器置信度。
- h_j ：层次一致性分数。
- v_j ：视觉语言一致性分数，例如 crop 与文本描述的 CLIP 相似度。
- a_j ：几何合理性分数，例如宽高比、面积、角度是否符合该类常识。
- $\beta_1, \beta_2, \beta_3, \beta_4$ ：四个分量的权重。

数值例子：设

$$d_j = 0.80, \quad h_j = 0.60, \quad v_j = 0.70, \quad a_j = 0.50,$$

且四个权重均为 0.5，则线性分数为：

$$u = 0.5(0.80 + 0.60 + 0.70 + 0.50) = 1.30.$$

因此：

$$q_j = \sigma(1.30) = \frac{1}{1 + e^{-1.30}} \approx 0.786.$$

若阈值为 0.75，该伪标签可被接收；若阈值为 0.85，则被拒绝。

总训练损失为：

$$\mathcal{L} = \mathcal{L}_{det}^{sup} + \lambda_h \mathcal{L}_{hier} + \lambda_p \sum_j q_j \left(\mathcal{L}_{cls}^{pseudo}(j) + \lambda_b \mathcal{L}_{box}^{pseudo}(j) \right).$$

符号含义：

- $\mathcal{L}$ ：总损失。
- $\mathcal{L}_{det}^{sup}$ ：有标注数据上的监督检测损失。
- $\mathcal{L}_{hier}$ ：层次一致性损失。
- $\mathcal{L}_{cls}^{pseudo}(j)$ ：第 j 个伪标签的分类损失。
- $\mathcal{L}_{box}^{pseudo}(j)$ ：第 j 个伪标签的框回归损失。
- q_j ：伪标签权重，越可靠影响越大。
- $\lambda_h, \lambda_p, \lambda_b$ ：不同损失项的权重。

5 当前定位失败诊断与 anchor repair

5.1 问题现象

目前轻量 scaffold 的主要问题不是阈值太高，而是定位和类别分布异常：

- 降低阈值后，decoded scores 仍然存在，但 mAP 没有实质改善。
- 预测类别集中到 small-vehicle、harbor、plane、ship 等少数类。
- 抽样 tile 中预测框有明显中心偏置，同类 IoU 很低。
- QueryGenerator 已经计算 query centers，但原 box head 未利用它们。

5.2 原始绝对解码

原始 box 解码近似为：

$$(x_i, y_i) = \sigma(\mathbf{t}_i^{xy}), \quad (w_i, h_i) = \sigma(\mathbf{t}_i^{wh}), \quad \theta_i = \frac{\pi}{2} \tanh(\mathbf{t}_i^\theta).$$

符号含义：

- $\mathbf{t}_i$ ：box head 输出的原始回归量。
- $\sigma(\cdot)$ ：sigmoid 函数。
- $\tanh(\cdot)$ ：双曲正切函数。

这个设计的问题是：每个 query 都可以自由预测整张图中任意中心点。如果训练早期缺少稳定空间约束，多个 query 可能塌缩到相似位置或中心区域。

5.3 锚定中心解码

anchor repair 的核心是把中心点绑定到 query center 附近：

$$(x_i, y_i) = \text{clip}\left(\mathbf{a}_i + \frac{s}{G} \tanh(\mathbf{t}_i^{xy}), 0, 1\right).$$

符号含义：

- $\mathbf{a}_i = (a_i^x, a_i^y)$ ：第 i 个 query 的网格中心。
- G ：query grid size，例如 $G = 16$ 。
- s ：center offset scale，例如 $s = 1.0$ 。
- $\text{clip}(\cdot, 0, 1)$ ：把坐标限制在 $[0, 1]$ 。

数值例子：若 $G = 16$ ， $s = 1.0$ ，query center 为

$$\mathbf{a}_i = (0.53125, 0.46875),$$

且 box head 输出 $\mathbf{t}_i^{xy} = (0.4, -0.2)$ ，则

$$\tanh(0.4) \approx 0.380, \quad \tanh(-0.2) \approx -0.197.$$

中心偏移为:

$$\Delta x = 0.380/16 \approx 0.0238, \quad \Delta y = -0.197/16 \approx -0.0123.$$

最终中心为:

$$(x_i, y_i) \approx (0.5551, 0.4564).$$

这样每个 query 只能在自身网格附近搜索, 降低无锚点全局回归的不稳定性。

6 从输入到输出的完整数值例子

本节假设一个具体例子, 帮助理解整个系统如何从原始遥感图像走到最终检测结果。为了便于计算, 数字经过简化, 但流程与真实实验一致。

6.1 步骤 1: 原始大图切片

假设原始遥感图像大小为:

$$6000 \times 6000.$$

训练时不能直接把整张大图送入检测器, 因此先切成 tile。设:

$$tile = 1024, \quad stride = 768.$$

单方向 tile 数量近似为:

$$n = \left\lfloor \frac{6000 - 1024}{768} \right\rfloor + 1 = \lfloor 6.48 \rfloor + 1 = 7.$$

因此一张大图大约得到:

$$7 \times 7 = 49$$

个 tile。若有 100 张原图, 则大约得到 4900 个 tile。真实数量会受边界补齐、空 tile 过滤和 overlap 策略影响。

现在取其中一个 tile:

$$I \in \mathbb{R}^{3 \times 1024 \times 1024}.$$

假设这个 tile 中有一辆 small-vehicle, 其真实旋转框为:

$$b^{gt} = (x, y, w, h, \theta) = (0.55, 0.46, 0.045, 0.020, 0.10).$$

这里坐标和宽高已经除以 1024 做归一化。换回像素坐标约为:

$$x = 0.55 \times 1024 = 563.2, \quad y = 0.46 \times 1024 = 471.0.$$

6.2 步骤 2: Backbone 提取特征

输入 tile 经过 backbone 后得到特征图。为了简化, 假设 backbone 输出:

$$F \in \mathbb{R}^{256 \times 64 \times 64}.$$

符号含义:

- 256: 通道数。
- 64×64 : 空间分辨率。
- 每个特征点大致对应原图 $1024/64 = 16$ 像素。

如果使用 FPN, 还会得到多个尺度, 例如:

$$P_3 \in \mathbb{R}^{256 \times 128 \times 128}, \quad P_4 \in \mathbb{R}^{256 \times 64 \times 64}, \quad P_5 \in \mathbb{R}^{256 \times 32 \times 32}.$$

当前轻量 scaffold 更简单, 但强基线通常会使用多尺度特征, 因为 DOTA 中 small-vehicle 和 ship 等目标尺度差异很大。

6.3 步骤 3: Query 网格生成

设 query grid size 为:

$$G = 16.$$

则共有:

$$Q = G^2 = 256$$

个 query。每个 query 有一个归一化中心:

$$\mathbf{a}_{u,v} = \left(\frac{u + 0.5}{G}, \frac{v + 0.5}{G} \right), \quad u, v \in \{0, \dots, 15\}.$$

假设 small-vehicle 附近的 query 是 $u = 8, v = 7$, 则:

$$\mathbf{a}_{8,7} = \left(\frac{8.5}{16}, \frac{7.5}{16} \right) = (0.53125, 0.46875).$$

这个中心离真实中心 $(0.55, 0.46)$ 很近, 适合负责该目标。

6.4 步骤 4: Anchored box 解码

检测头对这个 query 输出原始回归量:

$$\mathbf{t}_i = (t_x, t_y, t_w, t_h, t_\theta) = (0.40, -0.20, -3.00, -3.90, 0.064).$$

中心用 anchored decode:

$$(x_i, y_i) = \mathbf{a}_i + \frac{1}{16} \tanh(t_x, t_y).$$

因为:

$$\tanh(0.40) = 0.380, \quad \tanh(-0.20) = -0.197,$$

所以：

$$x_i = 0.53125 + 0.380/16 = 0.5550, \quad y_i = 0.46875 - 0.197/16 = 0.4564.$$

宽高用 sigmoid 解码：

$$w_i = \sigma(-3.00) = 0.0474, \quad h_i = \sigma(-3.90) = 0.0198.$$

角度为：

$$\theta_i = \frac{\pi}{2} \tanh(0.064) \approx 1.5708 \times 0.0639 = 0.100.$$

最终预测框为：

$$b_i = (0.5550, 0.4564, 0.0474, 0.0198, 0.100).$$

它与真实框

$$b^{gt} = (0.55, 0.46, 0.045, 0.020, 0.10)$$

非常接近，因此有机会取得较高 rotated IoU。

6.5 步骤 5: Prompt bank 分类

假设类别集合只看四类：

$$\mathcal{C} = \{\text{small-vehicle}, \text{large-vehicle}, \text{ship}, \text{harbor}\}.$$

对于 small-vehicle，构造三条 prompt：

$$\begin{aligned} p_1 &= \text{"a small vehicle in an aerial image"}, \\ p_2 &= \text{"a road vehicle smaller than a truck"}, \\ p_3 &= \text{"a tiny car-like object on road"}. \end{aligned}$$

假设文本编码和加权后得到类别嵌入 $\bar{e}_{sv}$ 。视觉 query 特征投影后为 $\phi(\mathbf{r}_i)$ 。为简化，只看余弦相似度：

$$\begin{aligned} \cos(\mathbf{r}_i, \bar{e}_{sv}) &= 0.78, & \cos(\mathbf{r}_i, \bar{e}_{lv}) &= 0.55, \\ \cos(\mathbf{r}_i, \bar{e}_{ship}) &= 0.30, & \cos(\mathbf{r}_i, \bar{e}_{harbor}) &= 0.22. \end{aligned}$$

设温度 $\tau = 0.1$ ，则 logits 为：

$$z = [7.8, 5.5, 3.0, 2.2].$$

softmax 后 small-vehicle 概率约为：

$$p_{sv} = \frac{e^{7.8}}{e^{7.8} + e^{5.5} + e^{3.0} + e^{2.2}} \approx 0.90.$$

因此该 query 的类别预测为 small-vehicle，置信度约为 0.90。

6.6 步骤 6：层次一致性检查

假设类别树中：

$$\text{vehicle} \rightarrow \text{small-vehicle}.$$

如果模型认为 small-vehicle 分数很高，但 vehicle 父类语义分数很低，就不合理。可定义：

$$h_i = \min(s_{\text{child}}, s_{\text{parent}}).$$

例如：

$$s_{\text{small-vehicle}} = 0.90, \quad s_{\text{vehicle}} = 0.82,$$

则：

$$h_i = 0.82.$$

若另一个预测是 harbor，但 crop 更像 vehicle，层次一致性可能低，从而在伪标签净化中被削弱。

6.7 步骤 7：伪标签净化打分

若这个 tile 是无标注数据，当前检测结果只是候选伪标签。设：

$$d_j = 0.90, \quad h_j = 0.82, \quad v_j = 0.76, \quad a_j = 0.88.$$

其中：

- $d_j = 0.90$ ：检测器分类置信度。
- $h_j = 0.82$ ：child-parent 层次一致性。
- $v_j = 0.76$ ：crop 与 “small vehicle” 文本的 VLM 相似度。
- $a_j = 0.88$ ：几何形状符合 small-vehicle，宽高比较合理。

设权重为：

$$\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0.5.$$

线性分数：

$$u = 0.5(0.90 + 0.82 + 0.76 + 0.88) = 1.68.$$

净化分数：

$$q_j = \sigma(1.68) \approx 0.843.$$

若阈值 $\tau_q = 0.80$ ，该伪标签被接受，并在训练中以权重 0.843 进入 loss。

6.8 步骤 8：Rotated NMS

假设同一辆车有两个候选框：

$$b_1 : s_1 = 0.90, \quad b_2 : s_2 = 0.83,$$


且 rotated IoU 为：

$$\text{rIoU}(b_1, b_2) = 0.72.$$

若 NMS 阈值为 $T_{nms} = 0.5$ ，则保留分数更高的 b_1 ，删除 b_2 。最终输出为：

$$(\text{small-vehicle}, 0.90, (0.5550, 0.4564, 0.0474, 0.0198, 0.100)).$$

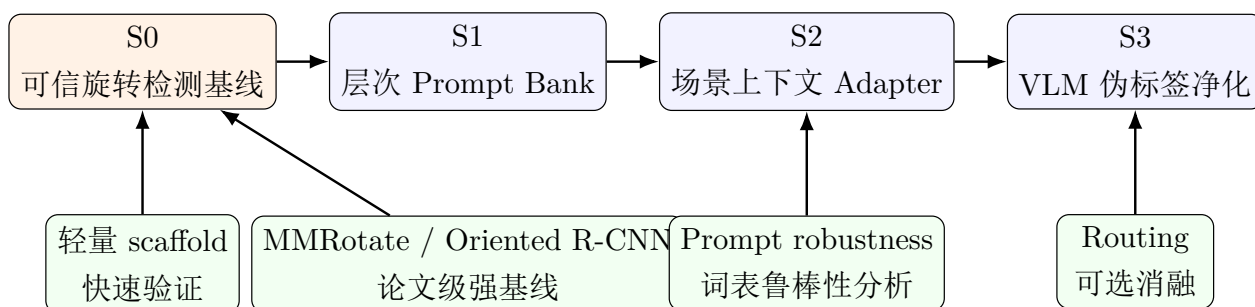
6.9 完整流程小结图



7 后续可转向的方向

7.1 几条路线之间的关系

当前不是只有一条路。更准确地说，有一条主线和几条备选线：



关键判断是：如果 S0 基线不可信，S1-S3 的提升就没有论文价值。因此强基线不是“额外工作”，而是论文能否成立的地基。

7.2 方向 A：继续修复轻量 scaffold

优点是工程成本低、和现有代码衔接最好；缺点是即使修复后也未必达到论文级检测性能。适合做快速 sanity check。

建议动作：

- 用 `dota_v15_anchor_repair.yaml` 跑 1-3 epoch。

- 诊断 best IoU、center bias、类别分布和 AP50。
- 如果 AP50 仍接近零，则停止在 scaffold 上堆叠创新模块。

scaffold 适合回答的问题：

- query center 是否能缓解中心偏置？
- 数据加载、坐标变换、rotated IoU、NMS 是否基本正确？
- prompt bank、context adapter、pseudo-label purification 的代码路径是否能跑通？

scaffold 不适合承担的问题：

- 不能用它证明方法达到 SOTA。
- 不能用 near-zero baseline 的轻微改善作为强论文证据。
- 不能把 hash text embedding 伪装成真实 VLM 能力。

7.3 方向 B：引入强旋转检测器作为 S0

这是最符合论文要求的方向。建议使用 MMRotate 或等价实现中的 Oriented R-CNN、RoI Transformer、ReDet。

优点：

- 更容易获得可信基线。
- 后续层次 prompt、context adapter、pseudo-label purification 的增益更有说服力。
- 审稿人更容易接受。

风险：

- 环境安装和 DOTA 格式适配成本更高。
- 需要明确区分 strong detector baseline 与本仓库 scaffold 的结果。

MMRotate 是什么

MMRotate 是 OpenMMLab 体系中的旋转目标检测工具箱，通常包含 DOTA 数据集处理、旋转框表示、旋转 IoU、旋转 NMS、主流检测器配置和训练评估脚本。它的价值在于减少我们手写检测器基础设施的风险。对本项目来说，MMRotate 可以提供可信 S0：

DOTA tile → standard OBB detector → 可信 mAP.

如果 S0 使用 MMRotate，GeoNexus-RSD 的创新可以转移到：

- 用层次 prompt 替换或辅助分类头；
- 用场景上下文调节类别语义；
- 用 VLM 净化半监督伪标签；
- 在强基线上做消融，而不是在弱 scaffold 上证明效果。

Oriented R-CNN

Oriented R-CNN 是两阶段旋转检测器。简化流程为：

$$I \rightarrow F \rightarrow \text{RPN proposals} \rightarrow \text{oriented RoI features} \rightarrow (c, b).$$

其中第一阶段生成候选区域，第二阶段对候选区域分类和回归旋转框。它适合作为基线，因为结构清楚、DOTA 上常用、结果通常比轻量 scaffold 可靠。

若把 GeoNexus-RSD 接到 Oriented R-CNN 上，可能的接法是：

- RPN 和 box regression 保持原始实现；
- RoI classification head 由固定线性分类器改为 prompt similarity；
- 对 RoI crop 计算 VLM agreement，用于伪标签过滤；
- 只在分类语义侧做轻量改造，避免破坏几何定位能力。

RoI Transformer

RoI Transformer 的核心思想是把水平候选框转换成旋转候选框，让特征和目标方向更对齐。简化流程为：

$$\text{horizontal RoI} \rightarrow \text{learned rotated RoI} \rightarrow \text{rotated detection}.$$

它适合遥感场景，因为飞机、船、桥、车辆都有任意方向。若使用它作为 S0，GeoNexus-RSD 仍然可以主要改分类语义和伪标签过滤，而不是重新设计几何模块。

ReDet

ReDet 强调旋转等变特征。直观理解：如果图像旋转，特征也应以可预测方式旋转，而不是完全改变。它适合旋转目标密集的航空图像，但实现和环境成本可能比 Oriented R-CNN 更高。

选择建议

如果目标是尽快得到可信论文结果，优先级建议为：

$$\text{Oriented R-CNN} > \text{RoI Transformer} > \text{ReDet} > \text{继续手写完整检测器}.$$

原因是 Oriented R-CNN 结构清楚，和 prompt classification head 的结合最直接。

7.4 方向 C：把当前工作定位成方法路线和失败分析

如果时间非常紧，可以把短论文先写成方法设计、流程复现和失败分析文档。优点是风险低；缺点是缺少强实验结果，不适合作为最终 JSTARS 投稿。

7.5 方向 D：缩小论文目标

若检测器基线长期不稳定，可以暂时缩小为：

- prompt robustness study;
- hierarchy-aware pseudo-label filtering study;
- reduced DOTA setup 上的 pipeline paper;
- workshop 或技术报告。

7.6 方向 E：只做层次提示和 prompt robustness

如果强检测器接入时间不足，可以先做一个较窄的实验：固定 detector，只改变类别文本描述，测试类别名、别名、父类描述、对比描述对结果的影响。这个方向的优点是实现简单，能够直接解释“prompt 是否有用”。缺点是如果 detector 本身很弱，prompt 的效果会被定位错误掩盖。

可设计四组 prompt：

- P_1 : 仅类别名,
- P_2 : 类别名 + 别名,
- P_3 : 类别名 + 父类层次,
- P_4 : 类别名 + 父类 + 对比描述.

比较指标包括 mAP、class-wise AP、small/large vehicle confusion、ship/harbor confusion。

7.7 方向 F：只做伪标签净化

如果检测器基线已经可用，但 prompt head 改造风险较高，可以先把 VLM 和层次结构用于伪标签过滤，而不改 detector 主体。流程为：

teacher detections $\rightarrow$ hierarchy + VLM + geometry filtering $\rightarrow$ student training.

优点是对检测器侵入小；缺点是需要额外 crop-text 模型，且 VLM 对遥感小目标可能不稳定。

7.8 方向 G：Routing 作为后续可选模块

Routing 的意思是让模型根据样本难度或场景选择不同分支。例如：

$$\mathbf{o}_i = \sum_{m=1}^M \pi_{i,m} \mathbf{o}_i^{(m)}, \quad \pi_i = \text{softmax}(R([\mathbf{g}, \mathbf{r}_i])).$$

符号含义：

- M ：分支数量，例如 flat prompt、hierarchy prompt、context prompt 三个分支。
- $\mathbf{o}_i^{(m)}$ ：第 m 个分支对第 i 个 query 的输出。
- $\pi_{i,m}$ ：第 i 个 query 使用第 m 个分支的权重。
- $R(\cdot)$ ：router 网络。

数值例子：假设三个分支输出类别 logit 分别为：

$$o^{(1)} = 5.0, \quad o^{(2)} = 6.2, \quad o^{(3)} = 5.7,$$

router 给出权重：

$$\pi = [0.2, 0.5, 0.3].$$

融合后：

$$o = 0.2 \times 5.0 + 0.5 \times 6.2 + 0.3 \times 5.7 = 5.81.$$

Routing 的风险是它会增加复杂度，而且在 S1-S3 没有稳定收益前，很难解释它到底解决了什么问题。因此当前只建议作为 S5 optional ablation。

8 当前主要问题与解决方案

问题	具体表现	可能解决方案
基线 AP 接近零	DOTA v1/v1.5 AP50 极低	优先修复定位路径；同时准备 MM-Rotate 强基线
定位中心偏置	预测框集中、同类 IoU 低	使用 query center anchored decode；检查坐标归一化和 tile 映射
类别塌缩	少数类别得分占优	检查类别权重、prompt embedding、loss 平衡和数据分布
伪标签噪声	小目标密集场景误检多	引入层次一致性、VLM agreement 和几何合理性过滤
论文 claim 风险	目前没有有效性能结果	只写流程和方法，不写未验证提升；所有数值标明 dataset/version

9 推荐执行顺序

推荐顺序如下：

1. 确认当前 GitHub 最新代码已经覆盖本地文件。
2. 构建本文档 PDF 和 canonical paper PDF，作为当前路线记录。
3. 在服务器上跑 `dota_v15_anchor_repair` 1-3 epoch。
4. 运行诊断脚本，比较 baseline 与 anchor repair 的定位质量。
5. 并行准备强旋转检测器 S0 baseline。
6. 只有当 S0 可信后，再运行 S1 层次提示、S2 上下文适配、S3 伪标签净化。

10 最终论文中应避免的表述

在没有真实结果前，应避免：

- 声称“显著提升 mAP”。
- 声称“open-vocabulary detection”，除非使用真实 VLM embedding 并做开放词表评估。
- 把 DOTA v1.0、v1.5、v2 的数值混在一个表里。
- 把 hash-based text embedding 写成 CLIP 或 RemoteCLIP。
- 把 near-zero scaffold baseline 当作论文基线。

11 一句话总结

GeoNexus-RSD 当前最合理的路线是：先用强旋转检测器或定位修复得到可信 S0，再在此基础上验证层次提示、场景上下文适配和 VLM 辅助伪标签净化；routing 和 compression 只能作为后续可选消融，不能成为当前主线。